GMM

Um quase abstract

O GMM, apesar de apresentado como uma técnica de clustering, pode ser entendido como uma tentativa de ajustar um RNG a um conjunto de dados. O RNG que queremos modelar é um conjunto de K gaussianas e possui um seguinte comportamento:

- Ao chamar o RNG, é sorteado uma das K gaussianas para gerar um dado
- A k-ésima gaussiana sorteia um dado.

Note que: embora o processo de sortear um dado apresente trivialidade(se já conhecido um conjunto de parâmetros que se ajuste bem ao seu conjunto de dados), estimar parâmetros apresenta dificuldade, visto que este admite múltiplas soluções.

Para estimar esses parâmetros, podemos fazer o seguinte:

- **Inverter o problema para algo mensurável:** este é feito por meio do Teorema de Bayes
- **Tentar maximizar a probabilidade do meu modelo gerar meu conjunto:** Conseguimos resolver isso iterativamente por meio do algoritmo *Expectation Maximization*.

O pertencimento a um grupo, nesse caso, é a probabilidade da k-ésima gaussiana ter gerado tal observação.

Modelando o "problema direto": O comportamento do RNG

Considere um conjunto de dados $\mathbf{X} \in \{\mathbf{x}_1, \ldots, \mathbf{x}_N\}$ que consiste em observações de uma variável aleatória $\mathbf{x}$ com D dimensões.

Quero criar um RNG que modele esses dados. Decido então aproximar o problema da seguinte forma:

Tenho K gaussianas que são responsáveis por gerar um valor, cada um com um conjunto de parâmetros dado por $\theta_k = \{\mu_k, \Sigma_k\}$. a probabilidade da k-ésima gaussiana gerar x_n é dada por

$$p(x_n|\theta_k) = \mathcal{N}(x_n|\theta_k)$$

Além disso, tenho uma variável aleatória categórica z_n que sorteia uma das K gaussianas e manda ela gerar um valor. Nesse caso, a probabilidade de z_n sortear a k-ésima gaussiana é

dada por:

$$p(z_n = k) = \pi_k,$$

Qualquer uma das gaussianas podem gerar x_n, e temos que levar em conta que nem todas as K gaussianas tem chances iguais de serem escolhidas. Nesse caso, para modelarmos a probabilidade de x_n ser sorteado, utilizamos a formula da probabilidade condicional

$$p(x_n) = \Sigma_{z_n} p(z_n) p(x_n|z_n)$$
$$p(x_n) = \Sigma_{k=1}^{K} \pi_k \mathcal{N}(x_n|\theta_k),$$

nesse contexto, chamamos π_k de coeficientes da mistura, que quando somados dão 1.

> Basicamente, o meu RNG:
>
> - sorteia uma das K gaussianas com z_n; e
> - manda essa gaussiana sortear um número, com probabilidade $\mathcal{N}(x_n|\theta_k)$

Invertendo o problema: Ajustando meu RNG a um conjunto de dados

O problema inverso

Como descrito, o GMM basicamente tenta ajustar um gerador de dados sintéticos a um conjunto de observações. Na seção anterior, vimos o processo de gerar os dados, no entanto, eu ainda não tenho uma boa estimativa do meu conjunto de parâmetros(vulgo, não sei $p(x_n)$). É possível ajustar o meu modelo a um conjunto de observações?

A formula que estabelece a relação entre o problema direto e o problema inverso é o Teorema de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$
$$p(z_n = k|x_n) = \frac{p(x_n|z_n = k)p(z_n = k)}{p(x_n)}$$
$$p(z_n = k|x_n) = \frac{\mathcal{N}(x_n|\theta_k)\pi_k}{\Sigma_{k=1}^{K} \pi_k \mathcal{N}(x_n|\theta_k)},$$

em que $p(z_n = k|x_n)$ representa a probabilidade de x_n ter sido gerado pelo k-ésimo cluster(gaussiana). Visto que $p(z_n = k|x_n)$ aparece recorrentemente na formulação,

introduzimos o simbolo $\gamma_{nk} = p(z_n = k|x_n)$.

Inferindo parâmetros para meu problema

Para encontrarmos uma solução sensata para meu problema, devemos levar em conta a probabilidade de meu modelo, dado pelo conjunto de parâmetros $\theta = \{\theta_1, \theta_2, \ldots, \theta_K\}$, gerar todo o meu conjunto de dados $\mathbf{X}$, essa probabilidade pode ser escrita como

$$p(\mathbf{X}|\theta) = \prod_{n=1}^{N} \sum_{k=1}^{K} \pi_k p(x_n|\theta_k)$$

$$\ell(\theta) = p(\mathbf{X}|\theta) = \prod_{n=1}^{N} \sum_{k=1}^{K} \pi_k \mathcal{N}(x_n|\theta_k).$$

Por conveniência matemática, observamos em forma logaritmica

$$\log \ell(\theta) = \sum_{n=1}^{N} \log \sum_{k=1}^{K} \pi_k \mathcal{N}(x_n|\theta_k).$$

> Por que não operar sobre $\ell(\theta)$
>
> - Derivada é mais complicada
> - Estabilidade numérica: valores muito pequenos podem resultar em underflow
> - No caso do GMM, ao aplicar $\log$, garantimos uma função monotônicamente crescente

Nós queremos maximizar a probabilidade do meu RNG gerar o meu conjunto de dados. O conjunto de parâmetros $\hat{\theta}$ que realiza esse feito é o resultado do seguinte problema de otimização

$$\hat{\theta} = \arg\max_{\theta} \left\{ \log \ell(\theta) \right\}.$$

É importante notar que não é possível determinar um $\hat{\theta}$ global, no entanto, conseguimos maximizar $\ell(\theta)$ para um conjunto de parâmetros θ fixos. Nesse caso, o máximo ocorre ao encontrar a região em que $\ell(\theta)$ muda de sinal, isto acontece quando

$$\frac{\mathrm{d}\ell(\theta)}{\mathrm{d}\theta} = 0,$$

o algoritmo *Expectation Maximization* se aproveita dessa definição para aproximar $\hat{\theta}$.

> Técnicamente acho que seria $\nabla \ell(\theta) = 0$ (o gradiente da função), pensando em θ como um conjunto de coordenadas, mas acredito que seja mais intuitivo explicar pelo ponto de vista de Cálculo I.

Expectation Maximization

Passo 0: Inicialização

Dar um chute para $\theta_1^{(\tau=0)}, \ldots, \theta_K^{(\tau=0)}$

Passo 1: Expectation

Para cada observação x_n e grupo k, avaliar

$$\gamma_{nk}^{(\tau)} = \frac{\mathcal{N}(x_n|\theta_k^{(\tau)})\pi_k^{(\tau)}}{\Sigma_{k=1}^{K}\pi_k^{(\tau)}\mathcal{N}(x_n|\theta_k^{(\tau)})}$$

Passo 2: Maximization

Conforme comentado anteriormente, o máximo da função para um θ fixo ocorre quando

$$\frac{\mathrm{d}\ell(\theta)}{\mathrm{d}\theta} = 0,$$

visto que há solução analítica para $\frac{\mathrm{d}\ell(\theta)}{\mathrm{d}\theta}$ (isto é, a solução é uma equação conhecida). Conseguimos maximizar localmente.

> Ver as equações do slide, não quero redigitar

Passo 3: Repetir

Visto que estimamos um novo conjunto $\theta^{(\tau+1)}$, podemos repetir os passos 2 e 3 usando $\theta^{(\tau+1)}$ como dado de entrada, maximizando $\ell(\theta)$ mais ainda. Dessa forma, com o passar das iterações, o modelo começa a se ajustar cada vez melhor ao conjunto de dados.